

Pontifícia Universidade Católica de Minas Gerais
Campus Poços de Caldas
Curso de Ciência da Computação

Relatório de Estágio Supervisionado

**Análise e Validação de Redes Neurais para Predição de Ativos
Financeiros Baseada em Gráficos de Candlestick**

Ciência da Computação / Inteligência Artificial Aplicada ao Mercado Financeiro

Aluno: Jules Eloísio Moraes Lima
Orientador: Cláudio Faria

7º semestre / 2026

1 Resumo

O presente trabalho tem como objetivo investigar, implementar e avaliar o desempenho de arquiteturas de redes neurais aplicadas à visão computacional para a predição de tendências de ativos financeiros. A previsão do mercado financeiro constitui um problema complexo e multifatorial, no qual técnicas de aprendizado profundo (*deep learning*) têm se destacado como abordagens promissoras para o reconhecimento de padrões em grandes volumes de dados. Nesse contexto, o projeto utiliza como entrada representações visuais de gráficos do tipo *candlestick*, buscando explorar a capacidade de modelos computacionais em identificar padrões relevantes e auxiliar na previsão de movimentos de mercado.

O pipeline de trabalho compreendeu a coleta automatizada de dados históricos do par de moedas USDT/BRL por meio da API da *exchange* Binance, bem como rotinas responsáveis pela conversão das séries temporais brutas em imagens de gráficos *candlestick* sob diferentes estratégias de normalização. Em seguida, foram implementadas e avaliadas duas abordagens principais: uma arquitetura de rede neural convolucional (*convolutional neural network*, CNN) customizada, utilizada como linha de base, e o modelo ResNet18 adaptado para aprendizado por transferência (*transfer learning*). Num primeiro momento, utilizou-se apenas a acurácia como métrica para avaliar a eficiência da rede base. No decorrer do processo, identificou-se a necessidade de incorporar métricas adicionais para uma comprovação mais profunda do desempenho, visto que a análise isolada da acurácia se mostrou rasa para o cenário financeiro. Então, os modelos foram avaliados por meio de um conjunto de métricas composto por Acurácia, F1-Score, a Área Sob a Curva ROC (ROC-AUC) e o Coeficiente de Correlação de Matthews (MCC).

Para observar o comportamento das redes em cenários mais condizentes com a realidade de mercado e testar diferentes dinâmicas de validação, substituiu-se o método estático inicial pela metodologia *Walk-Forward Validation* por fatiamento temporal, mitigando também o risco de vazamento de dados que ocorreria com a aplicação da validação cruzada tradicional (*k-fold cross-validation*).

Ambas as arquiteturas foram submetidas a uma sequência de testes empíricos com o objetivo de avaliar o impacto da variação de hiperparâmetros no processo de treinamento, incluindo resolução das imagens, número de épocas, tamanho da janela temporal, taxa de aprendizado (*learning rate*, LR) e decaimento dinâmico da taxa de

aprendizado (*learning rate decay*).

Os resultados indicam que a principal limitação observada está relacionada à dificuldade de generalização dos modelos para dados não vistos. Em vez de aprender padrões do mercado, as redes demonstraram tendência à memorização dos dados de treinamento, atingindo, em alguns experimentos, acurácia próxima ou igual a 100% nessa etapa, enquanto o desempenho em teste permaneceu na faixa aproximada de 50% a 55%. Esse comportamento caracteriza a ocorrência de *overfitting* e sugere que, por ser o mercado financeiro um ambiente altamente volátil e dependente de múltiplas variáveis, a representação isolada dos *candles* torna necessária a investigação de informações complementares, como sentimentos do cenário político ou dados macroeconômicos, para auxiliar na identificação de padrões preditivos.

2 Introdução

A predição de movimentos do mercado financeiro constitui um desafio complexo devido à influência simultânea de diversos fatores econômicos, comportamentais e institucionais sobre o preço dos ativos (YAQIN et al., 2026). Tradicionalmente, analistas e investidores utilizam a análise técnica como uma das formas de interpretar o comportamento dos preços, apoiando-se frequentemente em gráficos de *candlestick* para identificar tendências, regiões de suporte e resistência e possíveis padrões de reversão ou continuidade.

Os gráficos de *candlestick* representam visualmente a movimentação de preço de um ativo em determinado intervalo de tempo, geralmente por meio dos valores de abertura, fechamento, máxima e mínima. A combinação sequencial desses elementos permite observar padrões visuais associados ao comportamento do mercado, o que torna esse tipo de representação adequado para investigações envolvendo técnicas de visão computacional. Essa estratégia de conversão para o domínio bidimensional alinha-se com abordagens da literatura que buscam superar as limitações da aplicação direta de redes neurais sobre dados temporais unidimensionais por meio da extração de características espaciais em imagens (SOLANKI; JHA, 2026).

Com os avanços recentes na área de inteligência artificial, especialmente em *deep learning*, tornou-se possível investigar modelos capazes de reconhecer automaticamente padrões em dados visuais. Nesse contexto, trabalhos como o de Kusuma et al. (2019) exploram o uso de redes neurais profundas aplicadas a gráficos

de *candlestick* para a predição de movimentos do mercado financeiro. Críticas na literatura apontam que muitos desses modelos falham por simplificar excessivamente a dinâmica dos ativos ou por não considerarem de forma explícita as estruturas complexas e a constante evolução do mercado (FRIDAY et al., 2026).

Dessa forma, este projeto tem como motivação principal investigar a viabilidade da aplicação de modelos de visão computacional na interpretação automatizada de gráficos financeiros. Para isso, foram utilizadas imagens geradas a partir de séries temporais de preços, tendo como estudo de caso o par de moedas USDT/BRL, com dados coletados por meio da API da *exchange* Binance. O escopo do trabalho concentrou-se na construção do pipeline de coleta e pré-processamento dos dados, bem como na implementação, treinamento e avaliação comparativa de uma rede neural convolucional customizada, utilizada como linha de base experimental, e de uma arquitetura ResNet18 integrada via aprendizado por transferência.

A análise realizada expandiu a avaliação experimental por meio da aplicação da metodologia *Walk-Forward Validation* e do cálculo de um conjunto de métricas de avaliação, incluindo Acurácia, F1-Score, ROC-AUC e MCC. Essa expansão fornece o embasamento necessário para discutir a previsibilidade do ativo e delimitar o desempenho de abordagens baseadas em representações gráficas.

3 Objetivos

3.1 Objetivo Geral

Investigar, implementar e avaliar o desempenho de diferentes arquiteturas de redes neurais baseadas em visão computacional na predição de tendências de ativos financeiros, utilizando como entrada representações visuais de gráficos de *candlestick*.

O escopo deste trabalho compreendeu o desenvolvimento do *pipeline* completo de coleta e pré-processamento de dados, bem como a implementação, o treinamento e a avaliação comparativa entre uma rede neural convolucional customizada, utilizada como linha de base experimental, e a arquitetura ResNet18.

3.2 Objetivos Específicos

- Realizar o estudo de fundamentos de análise técnica para compreender a

semântica e os padrões visuais presentes nos gráficos de *candlestick*;

- Desenvolver *scripts* para a coleta automatizada de dados históricos de ativos financeiros, com foco no par USDT/BRL por meio da API da Binance;
- Implementar um *pipeline* de pré-processamento para converter séries temporais financeiras em representações visuais de gráficos *candlestick*;
- Implementar e treinar uma arquitetura de rede neural convolucional customizada para estabelecer a linha de base experimental do projeto;
- Integrar e avaliar a arquitetura ResNet18, comparando sua capacidade de extração de características em relação à linha de base;
- Avaliar empiricamente o impacto de diferentes configurações e hiperparâmetros no desempenho dos modelos, incluindo resolução das imagens, tamanho da janela temporal, número de épocas, estratégias de normalização, *learning rate* e *learning rate decay*;
- Aplicar a metodologia *Walk-Forward Validation* para testar o comportamento das redes sob fatiamento temporal contínuo, mitigando o risco de vazamento de dados;
- Analisar o desempenho dos modelos com base em um conjunto de métricas de classificação composto por Acurácia, F1-Score, ROC-AUC e MCC, identificando limitações de generalização e ocorrência de *overfitting*.

4 Detalhamento das Atividades Desenvolvidas

Esta seção apresenta as principais atividades desenvolvidas no projeto, abrangendo desde a coleta dos dados financeiros até a construção do conjunto de imagens, implementação das arquiteturas de redes neurais, estratégia de validação temporal e formulação das métricas de avaliação. O desenvolvimento foi organizado em módulos, de modo a estruturar o fluxo completo do sistema: aquisição dos dados, pré-processamento, geração das imagens, treinamento dos modelos e avaliação dos resultados.

4.1 Coleta e Organização dos Dados

A primeira etapa desenvolvida consistiu na coleta automatizada dos dados históricos do ativo financeiro utilizado nos experimentos. Para isso, foram implementados *scripts* em linguagem Python responsáveis por acessar a API da

exchange Binance e extrair informações referentes ao par de moedas USDT/BRL.

O conjunto de dados foi composto por 1.000 dias de negociação. As informações extraídas contemplaram os principais atributos financeiros presentes em séries temporais de mercado: preço de abertura, preço de fechamento, máxima, mínima e volume negociado. Após a coleta, os dados foram armazenados em um arquivo no formato CSV, utilizado como entrada para os módulos posteriores de pré-processamento e geração das imagens *candlestick*. Essa separação permitiu organizar o fluxo do projeto em etapas independentes, distinguindo o processo de aquisição dos dados da etapa de transformação visual das amostras.

Embora o volume tenha sido extraído e armazenado junto aos demais atributos financeiros, nesta etapa preliminar os experimentos concentraram-se nas representações visuais baseadas nos preços de abertura, fechamento, máxima e mínima. A exclusão do indicador de volume mantém a conformidade com as configurações de melhor desempenho documentadas por Kusuma et al. (2019), em que investigações anteriores indicaram que este atributo não trouxe ganhos expressivos de desempenho para a modelagem visual.

4.2 Pré-processamento e Definição dos Rótulos

Para transformar os dados financeiros em um problema de aprendizado supervisionado, foi adotada uma estratégia de criação de amostras por janelas deslizantes (*sliding window*) sobre a série temporal. Essa abordagem consiste em percorrer o histórico de preços com uma janela de tamanho fixo, de modo que cada amostra represente um intervalo contínuo de negociação.

Foram avaliadas janelas de 20 e 30 dias. Cada janela foi utilizada como base para a geração de uma imagem de gráfico candlestick, fornecendo ao modelo um contexto visual anterior ao movimento que se desejava prever.

O rótulo de cada amostra foi definido com base na direção do preço de fechamento do dia imediatamente posterior à janela analisada. Dessa forma, quando o fechamento posterior apresentava valorização em relação ao fechamento anterior, a amostra era classificada como tendência de alta (*UP*). Caso contrário, era classificada como tendência de baixa (*DOWN*). Assim, o problema foi estruturado como uma tarefa de classificação binária.

4.3 Geração das Imagens Candlestick

Após a organização das janelas temporais, foi desenvolvido um *pipeline* responsável por converter cada intervalo de dados financeiros em uma representação visual no formato de gráfico *candlestick*. Essa etapa permitiu estruturar o problema de predição como uma tarefa de visão computacional, na qual a rede neural recebe imagens como entrada em vez de valores tabulares diretamente.

As imagens foram geradas de forma simplificada, destacando apenas os componentes visuais dos *candles*, isto é, seus corpos e pavios, formados a partir dos preços de abertura, fechamento, máxima e mínima. Nesta etapa, não foram incluídos elementos adicionais como eixos, legendas, grades, textos ou representação gráfica do volume negociado. Essa escolha teve como objetivo manter a entrada visual mais direta e concentrada na formação dos *candles*.

Para ilustrar a geração das imagens e o processo de rotulagem dinâmica por meio das janelas deslizantes, a Figura 1 apresenta três imagens consecutivas geradas pelo pipeline. Como o deslocamento entre as janelas é de apenas um dia, o dia imediatamente posterior ao fechamento de uma amostra passa a corresponder ao último *candle* inserido na imagem subsequente. Ao analisar o último *candle* da Imagem 2, que representa o dia posterior ao término da janela da Imagem 1, constata-se que o preço de fechamento foi superior ao do dia anterior, fazendo com que a Imagem 1 receba o rótulo "*up*". Por outro lado, verifica-se que o último *candle* da Imagem 3 representa uma desvalorização em relação ao fechamento final da janela anterior, resultando na atribuição do rótulo "*down*" para a Imagem 2. Esse mecanismo de varredura e rotulagem repete-se sequencialmente ao longo de toda a série histórica do ativo.




Figura 1 – Exemplo de sequenciamento e rotulagem dinâmica de três imagens de candlesticks consecutivas via janela deslizante, demonstrando a atribuição dos rótulos de alta ("up") e de baixa ("down") a partir do candle de fechamento do dia posterior

A resolução das imagens foi tratada como um dos hiperparâmetros avaliados durante os experimentos. Foram geradas imagens nas resoluções de 50x50, 100x100 e 224x224 pixels, com o objetivo de comparar diferentes níveis de detalhamento visual e custo computacional. Em resoluções menores, há menor demanda de processamento, mas também maior risco de perda de detalhes relevantes dos candles. Já resoluções maiores preservam melhor a estrutura visual dos gráficos, embora exijam maior capacidade computacional durante o treinamento.

4.4 Normalização das Imagens

Antes de serem utilizadas como entrada da rede neural, as imagens geradas passaram por um processo de normalização estatística. Inicialmente, considerou-se a possibilidade de utilizar parâmetros genéricos de normalização empregados em modelos treinados sobre bases amplas de imagens, como a ImageNet. No entanto, por se tratar de um domínio visual específico, composto por gráficos financeiros e não por imagens naturais, optou-se por calcular a média e o desvio padrão diretamente a partir do próprio conjunto de imagens do projeto.

Essa normalização customizada foi aplicada aos canais de cor RGB das imagens, buscando adequar a escala dos valores de entrada e favorecer a estabilidade do processo de treinamento. Nos experimentos iniciais realizados, observou-se que a normalização específica do *dataset* contribuiu para acelerar a convergência do modelo durante o treinamento, embora não tenha sido suficiente para

resolver o problema de generalização observado nos dados de teste.

4.5 Implementação das Arquiteturas das Redes Neurais

Para a construção dos modelos preditivos, foi utilizado o framework PyTorch. Foram avaliadas duas abordagens estruturais:

4.5.1 Rede Neural Convolucional Baseline

A arquitetura adotada foi baseada no modelo proposto por Kusuma et al. (2019), utilizado como referência inicial para estabelecer uma linha de base experimental no projeto.

De forma geral, a rede implementada seguiu a estrutura da CNN apresentada no artigo de referência, composta por blocos de camadas convolucionais 2D, camadas de MaxPooling, camadas de regularização por Dropout e, ao final, camadas densas responsáveis pela classificação. No modelo de Kusuma et al. (2019), a arquitetura utiliza quatro camadas convolucionais com função de ativação ReLU, intercaladas com camadas de MaxPooling, seguidas por etapas de Dropout, uma camada densa intermediária e uma camada final com duas saídas, correspondente à classificação binária do movimento do ativo.

As camadas convolucionais têm a função de extrair padrões visuais das imagens de entrada, como bordas, formas e combinações entre corpos e pavios dos *candles*. As camadas de MaxPooling reduzem a dimensionalidade dos mapas de características, preservando as ativações mais relevantes e tornando a representação mais compacta para as etapas seguintes. Já as camadas de Dropout atuam como mecanismo de regularização, reduzindo a dependência excessiva entre neurônios durante o treinamento e buscando mitigar o *overfitting*.

Após a extração das características visuais, as camadas densas realizam a combinação dessas informações para produzir a classificação final da amostra em uma das duas classes possíveis: tendência de alta ou tendência de baixa. O treinamento foi conduzido utilizando a função de perda Cross-Entropy, adequada para problemas de classificação binária ou multiclasse, em conjunto com o otimizador Adam, responsável por ajustar os pesos da rede ao longo das épocas de treinamento.

4.5.2 ResNet18

Como alternativa à linha de base, integrou-se ao projeto a arquitetura ResNet18

operando com a técnica de aprendizado por transferência (*transfer learning*).

O modelo utiliza uma infraestrutura de blocos residuais profundos inicializada com pesos pré-treinados obtidos no conjunto ImageNet, o que possibilita o reaproveitamento de extratores de características geométricas fundamentais. Para adaptar a rede ao problema de classificação binária de gráficos de candlestick deste projeto, a camada totalmente conectada final original (*fully connected layer*) foi modificada, sendo substituída por um bloco personalizado contendo uma camada de regularização Dropout configurada com taxa de descarte de 0,5 e uma camada linear de saída contendo duas unidades neurais correspondentes às classes *UP* e *DOWN*.

4.6 Estratégia de Validação Temporal

Nas estratégias de validação temporal, inicialmente o treino e teste foi dividido de forma estática em 80% para o treino e 20% para o teste. Após isso, pensou-se em utilizar outro método de divisão das imagens, considerando a validação cruzada tradicional (*k-fold cross-validation*). Porém, ao verificar que essa abordagem poderia introduzir um vazamento de dados (*data leakage*), o que é extremamente importante não ocorrer no mercado financeiro devido à quebra da ordem cronológica das séries de preços, buscou-se a utilização do método *Walk-Forward Validation*.

A validação *Walk-Forward* funciona preservando a cronologia linear dos dados de mercado e simula as condições reais de operação de um sistema de negociação. Esse método divide os dados históricos em múltiplos subconjuntos sequenciais chamados blocos (*folds*).

Como exemplo de aplicação no projeto, utilizou-se a classe *TimeSeriesSplit* configurada com 5 fatiamentos temporais. No primeiro fatiamento, o modelo é treinado utilizando um intervalo inicial da série (por exemplo, os dias 1 a 200) e testado de forma independente no bloco imediatamente futuro (dias 201 a 400). No fatiamento seguinte, a base de treinamento se expande acumulando os dados cronológicos anteriores (dias 1 a 400) e a validação é conduzida em um novo período futuro (dias 401 a 600), repetindo esse ciclo sucessivamente sem que informações do futuro sejam expostas ao modelo na fase de ajuste de pesos.

4.6 Conjunto de Métricas de Avaliação

No conjunto de métricas de avaliação, identificou-se a necessidade de ir além do uso isolado da acurácia, visto que essa métrica isolada pode mascarar distorções

em domínios sujeitos a desbalanços de classes ou tendências fortes de mercado. Como exemplo prático dessa limitação, se em um determinado período histórico o preço do ativo analisado subiu em 90% das vezes e a rede neural classificar invariavelmente todas as amostras como tendência de alta (*UP*), a acurácia final obtida seria de 90%. Apesar de o percentual parecer elevado, o modelo não teria aprendido nenhum padrão preditivo real ou capacidade de discernimento, gerando uma análise rasa e um resultado desvinculado da realidade operacional.

Por esse motivo, viu-se a necessidade de utilizar outras métricas para tornar a avaliação mais confiante e precisa. Foram incorporadas as métricas F1-Score, ROC-AUC e o MCC. O cálculo conjunto dessas métricas permite mensurar de forma estatisticamente rigorosa a capacidade das redes convolucionais em gerar sinais preditivos reais, penalizando vieses decorrentes de palpites puramente aleatórios ou direcionais.

5 Resultados e Discussão

Após a implementação do pipeline de coleta, pré-processamento, geração de imagens e treinamento das redes, os modelos foram submetidos a uma sequência de testes experimentais sob diferentes configurações de hiperparâmetros.

O processo de avaliação foi conduzido de forma evolutiva, com o objetivo de analisar a capacidade de aprendizado das arquiteturas, sua convergência durante o treinamento e o desempenho em dados não vistos. Para isso, a validação iniciou-se com testes sob divisão estática tradicional, progrediu para simulações temporais dinâmicas via metodologia *Walk-Forward Validation* e finalizou com uma análise comparativa utilizando uma ResNet.

5.1 Experimentos Iniciais com Divisão Estática

Na fase inicial do projeto, os experimentos utilizaram uma arquitetura de rede neural convolucional baseada no modelo de Kusuma et al. (2019), avaliada por meio de uma divisão estática padrão na qual 80% das imagens geradas integraram o conjunto de treinamento e as 20% restantes compuseram o conjunto de teste. O foco desta etapa concentrou-se na análise da acurácia e na verificação da capacidade de convergência do modelo sob variações de hiperparâmetros. A Tabela 1 apresenta o resumo dos resultados coletados nesta fase.

Tabela 1 – Resumo dos experimentos iniciais realizados

Experimento	Janela	Resolução	Épocas	Acurácia Treino	Acurácia Teste	Observação Principal
EXP-01	20 dias	50x50	10	52.87%	45.92%	Modelo não convergiu adequadamente
EXP-02	20 dias	50x50	50	81.48%	55.10%	Melhora no treino, mas com indícios de overfitting
EXP-03	20 dias	50x50	50	58.62%	46.94%	Decaimento da taxa de aprendizado aplicado de forma prematura
EXP-04	20 dias	50x50	50	88.25%	52.04%	Normalização específica acelerou a convergência, mas não resolveu a generalização
EXP-05	20 dias	224x224	50	100.00%	51.53%	Alta acurácia no treino, com baixo desempenho em teste
EXP-06	30 dias	224x224	50	100.00%	55.15%	Melhor resultado de teste, mas ainda com forte overfitting
EXP-07	30 dias	100x100	50	97.42%	50.00%	Resolução intermediária não melhorou a generalização
EXP-08	30 dias	224x224	50	99.61%	48.45%	Taxa de aprendizado maior com decaimento não trouxe ganho em teste

Os resultados indicam que a arquitetura implementada foi capaz de aprender os padrões presentes no conjunto de treinamento, especialmente nos experimentos com maior número de épocas e imagens de maior resolução. No entanto, esse aprendizado não se refletiu de forma consistente no conjunto de teste. Em diferentes configurações, a acurácia de treinamento atingiu valores muito elevados, chegando a 100% em alguns experimentos, enquanto a acurácia de teste permaneceu próxima da faixa de 50% a 55%.

Esse comportamento evidencia a ocorrência de *overfitting*, isto é, uma tendência do modelo a memorizar características específicas do conjunto de treinamento em vez de aprender padrões suficientemente generalizáveis para dados

não vistos. O fenômeno tornou-se mais evidente nos experimentos EXP-05 e EXP-06, nos quais a rede atingiu acurácia perfeita no treinamento, mas manteve desempenho limitado no teste.

O EXP-01, utilizado como linha de base inicial, apresentou baixo desempenho tanto no treinamento quanto no teste, indicando dificuldade de convergência com apenas 10 épocas e imagens de 50x50 pixels. Com o aumento para 50 épocas no EXP-02, houve melhora significativa na acurácia de treino, demonstrando que o modelo passou a aprender os dados apresentados. Entretanto, a diferença entre treino e teste já indicava limitação de generalização.

Nos experimentos seguintes, foram avaliadas estratégias como decaimento da taxa de aprendizado, normalização específica do conjunto de imagens, aumento da resolução e ampliação da janela temporal. A normalização customizada contribuiu para melhorar o processo de convergência, enquanto a janela de 30 dias apresentou o melhor desempenho de teste observado, com acurácia de 55,15% no EXP-06. Ainda assim, a diferença entre a acurácia de treino e teste permaneceu elevada.

A variação da resolução das imagens também apresentou resultados relevantes. Imagens em 50x50 pixels apresentaram menor custo computacional, mas limitaram a representação visual dos candles. A resolução de 224x224 pixels preservou melhor os detalhes gráficos e favoreceu o aprendizado no conjunto de treinamento, porém não foi suficiente para melhorar substancialmente a generalização. Já a resolução intermediária de 100x100 pixels não apresentou ganho relevante, resultando em desempenho de teste equivalente a 50%.

De modo geral, os resultados indicam que o ajuste isolado de hiperparâmetros não foi suficiente para superar a limitação de generalização observada na arquitetura convolucional inicial. As variações testadas contribuíram para começar a compreender o comportamento do modelo, mas viu-se a necessidade de entender melhor o motivo dessa diferença e confirmar se o comportamento é real por meio da avaliação de outras métricas de desempenho. Constatou-se também a necessidade da utilização de outras abordagens metodológicas, como a aplicação do método *Walk-Forward Validation* e a avaliação de uma arquitetura alternativa como a ResNet.

5.2 Transição para a Validação Walk-Forward

A limitação central da divisão estática reside no fato de o treinamento ocorrer em um único intervalo histórico fixo e o teste se concentrar em um período

subsequente isolado. No mercado financeiro, esse desenho metodológico pode induzir a avaliações distorcidas, pois o período escolhido para o teste pode conter anomalias ou características macroeconômicas singulares. Caso ocorram eventos geopolíticos ou econômicos específicos nesse intervalo de teste, os padrões de comportamento das cotações tornam-se únicos e inteiramente diferentes daqueles observados na fase de treinamento, impedindo que a avaliação reflita a real capacidade do modelo de operar em diferentes cenários de mercado.

Diante desse cenário, considerou-se inicialmente a aplicação do método de validação cruzada tradicional (*k-fold cross-validation*). Contudo, a análise operacional dessa técnica revelou que sua utilização sobre séries temporais financeiras acarreta vazamento de dados. Como o *k-fold* convencional embaralha as amostras de forma aleatória, o modelo acaba utilizando dados do futuro durante a etapa de treinamento para prever dados do passado no conjunto de teste, quebrando a cronologia linear do mercado financeiro e invalidando a integridade estatística dos testes. Para contornar essa restrição, adotou-se a estratégia Walk-Forward Validation, dividindo os dados cronologicamente e garantindo que o modelo seja avaliado em múltiplos cenários futuros consecutivos sem contato com informações adiantadas no tempo.

Os experimentos mais relevantes da rede neural convolucional foram repetidos sob a metodologia *Walk-Forward* com 5 fatiamentos temporais (*folds*). Incorporou-se um conjunto expandido de métricas para validar com maior nível de confiança se o comportamento observado da rede correspondia a um aprendizado real ou a um comportamento equivalente a palpites aleatórios. A Tabela 2 apresenta o desempenho médio obtido nesta fase.

Tabela 2 – Resultados médios da arquitetura CNN base sob a metodologia Walk-Forward Validation (5 folds). Em todos os experimentos desta etapa, utilizou-se a normalização customizada do próprio dataset e uma janela temporal de 30 dias.

Experimento	Resolução	Learning Rate	Épocas	Acur. Treino	Acur. Teste	F1 Score	ROC AUC	MCC
EXP-01 (WF)	50x50	0,0001	10	54,48%	51,18%	0,3621	0,5127	-0,0016
EXP-02 (WF)	50x50	0,0001	50	77,76%	54,78%	0,5412	0,5493	0,0930

EXP-03 (WF)	50x50	0,001 (Decay)	50	86,93%	53,04%	0,5271	0,5482	0,0723
EXP-04 (WF)	224x224	0,0001	50	99,22%	52,17%	0,5173	0,5370	0,0414
EXP-05 (WF)	100x100	0,0001	50	92,22%	54,53%	0,5404	0,5492	0,0886
EXP-06 (WF)	224x224	0,001 (Decay)	50	96,53%	52,80%	0,5264	0,5510	0,0596

A inclusão das métricas adicionais ajudou a confirmar que a rede operava em patamares próximos à aleatoriedade. Os valores de F1-Score próximos a 0,50 e o coeficiente de MCC virtualmente zerado indica a ausência de um padrão preditivo robusto. A aplicação do método Walk-Forward Validation, por mais que traga o modelo para um cenário mais realista do mercado financeiro ao testar o sistema em diferentes ambientes e condições econômicas, não promoveu mudanças significativas nos resultados. Por se tratar de uma abordagem metodologicamente mais rigorosa e condizente com a realidade prática, o desempenho médio geral tendeu a se manter ligeiramente abaixo das marcas obtidas na divisão estática inicial.

Foi observado também que, embora em alguns fatiamentos temporais isolados o modelo tenha atingido acurácia de validação por volta de 60%, essa marca foi acompanhada por uma taxa de perda (*loss*) elevada. Esse comportamento caracteriza a persistência do *overfitting*. A Figura 2 apresenta as curvas de evolução geradas durante o processo, expondo graficamente o fenômeno do *overfitting* por meio da divergência acentuada entre o desempenho do treino e do teste.




Figura 2 – Gráficos de evolução de acurácia e perda por época em fatiamentos da validação Walk-Forward, evidenciando o comportamento de *overfitting*

5.3 Experimentos com a Arquitetura ResNet18

Na etapa final da investigação, realizou-se a avaliação utilizando a arquitetura ResNet18, aplicando as configurações de hiperparâmetros que se mostraram mais relevantes nos testes com a CNN baseline. Para verificar o impacto do tratamento estatístico dos dados visuais de entrada, testaram-se duas estratégias de normalização: a customizada (*custom*), extraída dos valores de média e desvio padrão do próprio conjunto de gráficos do projeto, e a normalização padrão do dataset ImageNet. Os resultados estão sintetizados na Tabela 3.

Tabela 3 – Resultados comparativos de estratégias de normalização na arquitetura ResNet18 sob validação Walk-Forward (5 folds). Ambos os experimentos apresentados utilizaram janela temporal de 30 dias e foram treinados ao longo de 50 épocas.

Exp.	Resolução	Learning Rate	Norm.	Acur. Treino	Acur. Teste	F1 Score	ROC AUC	MCC
EXP-07 (WF)	224x224	0,0001	ImageNet	99,10%	52,55%	0,4997	0,5545	0,0626
EXP-08 (WF)	224x224	0,0001	Custom	99,41%	52,67%	0,5043	0,5198	0,0539

Os dados demonstram que a utilização de um modelo mais complexo e pré-treinado como a ResNet18 não resultou em ganhos expressivos na predição do ativo. O modelo apresentou alta capacidade de convergência na etapa de treinamento, ultrapassando 96% de acertos em poucas épocas, mas manteve os resultados estagnados na faixa de 50% a 52%, com o coeficiente MCC indicando comportamento estatístico aleatório.

Os testes conduzidos com a normalização customizada e com a parametrização padrão da ImageNet resultaram em desempenhos equivalentes, sem variações significativas que indicassem superioridade de alguma técnica. A ausência de evolução com a troca de arquiteturas e métodos de normalização sugere que o limitador do desempenho não está associado à capacidade de processamento de formas geométricas pelas redes neurais, mas sim à restrição informativa de modelos baseados unicamente em representações gráficas monomodais de candlesticks diante da volatilidade característica do mercado financeiro.

6 Conclusões

O presente trabalho cumpriu os objetivos propostos ao investigar, implementar e avaliar um pipeline de visão computacional para a predição de tendências no mercado financeiro. A pesquisa demonstrou que a conversão de séries temporais do par USDT/BRL em imagens de candlesticks permite a aplicação direta de redes neurais profundas, mas também evidenciou desafios significativos de generalização.

Os experimentos mostraram que tanto a arquitetura CNN customizada quanto a ResNet18 apresentaram um comportamento de expressivo overfitting. Ambas as redes atingiram acurácias próximas ou igual a 100% no conjunto de treinamento, porém o desempenho de validação estabilizou-se invariavelmente na faixa de 50% a 55%.

Durante o desenvolvimento do projeto, identificou-se a necessidade de utilizar métodos de validação mais rigorosos. A adoção da metodologia Walk-Forward Validation provou-se essencial ao preservar a cronologia dos preços e simular de forma fiel as condições reais de operação do mercado, mitigando o grave risco de vazamento de dados que ocorreria no uso de partições estáticas ou validação cruzada tradicional.

Em conjunto com o aprimoramento da validação temporal, constatou-se a necessidade de incorporar métricas estatísticas mais avançadas para complementar a avaliação, superando as limitações analíticas de uma métrica simples como a acurácia. A análise de indicadores como F1-Score, ROC-AUC e o Coeficiente de Correlação de Matthews (MCC) revelou que, fora da amostra de treino, as classificações estabilizaram-se com índices próximos a zero, evidenciando um desempenho estatisticamente equivalente a escolhas aleatórias.

Diante da ausência de melhorias mesmo com o uso de modelos mais profundos e diferentes estratégias de normalização, os resultados sugerem que a principal limitação do sistema pode estar relacionada à escassez informativa da entrada visual monomodal. A representação geométrica isolada dos candles parece não fornecer sinal suficiente para que o modelo capture o ruído macroeconômico e as constantes mudanças de regime inerentes a ativos de alta volatilidade.

Por conseguinte, como trabalhos futuros, recomenda-se investigar a inclusão de informações adicionais nas imagens utilizadas pelo modelo, além dos próprios

candles, de forma a enriquecer os dados disponíveis para o aprendizado. A incorporação de elementos como a representação visual de indicadores técnicos sobrepostos ou gradientes associados ao sentimento do mercado apresenta-se como uma abordagem promissora para o desenvolvimento de sistemas preditivos mais robustos.

7 Bibliografia

KUSUMA, R. M. I. et al. Using Deep Learning Neural Networks and Candlestick Chart Representation to Predict Stock Market. arXiv preprint arXiv:1903.12258, 2019. Disponível em: <https://arxiv.org/abs/1903.12258>. Acesso em: 22 jun. 2026.

YAQIN, R. A. et al. Stock Price Forecasting Using LSTM with Cross-Validation. Vokasi Unesa Bulletin of Engineering, Technology and Applied Science (VUBETA), v. 3, n. 1, p. 64-79, 2026. Disponível em: <https://journal.unesa.ac.id/index.php/vubeta/article/view/45130>. Acesso em: 22 jun. 2026.

SOLANKI, N.; JHA, M. From Time Series to Images: A GAF-ResNet-LSTM Framework for Asset Selection and Portfolio Optimization. IEEE Access, v. 14, p. 1-16, 2026. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=11316110>. Acesso em: 22 jun. 2026.

FRIDAY, I. K. et al. A Meta-Adaptive Framework Combining Gated Attention Mechanisms and Feature-Wise Modulation for Multi-Horizon Stock Price Movement Prediction. IEEE Access, v. 14, p. 26603-26625, 2026. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=11389759>. Acesso em: 22 jun. 2026.