

Pontifícia Universidade Católica de Minas Gerais
Campus Poços de Caldas
Curso de Ciência da Computação

Relatório de Estágio Supervisionado

**Análise e Validação de Redes Neurais para Predição de Ativos
Financeiros Baseada em Gráficos de Candlestick**

Ciência da Computação / Inteligência Artificial Aplicada ao Mercado Financeiro

Aluno: Jules Eloísio Moraes Lima
Orientador: Cláudio Faria

7º semestre / 2026

1 Resumo

O presente trabalho tem como objetivo investigar, implementar e avaliar o desempenho de arquiteturas de redes neurais aplicadas à visão computacional para a predição de tendências de ativos financeiros. A previsão do mercado financeiro constitui um problema complexo e multifatorial, no qual técnicas de aprendizado profundo (*deep learning*) têm se destacado como abordagens promissoras para o reconhecimento de padrões em grandes volumes de dados. Nesse contexto, o projeto utiliza como entrada representações visuais de gráficos do tipo *candlestick*, buscando explorar a capacidade de modelos computacionais em identificar padrões relevantes e auxiliar na previsão de movimentos de mercado.

Até o momento, foi concluída a primeira fase do projeto, composta pela implementação do pipeline inicial de coleta, pré-processamento e treinamento. Foram desenvolvidos scripts em linguagem Python para a extração de dados históricos do par de moedas USDT/BRL por meio da API da *exchange* Binance, bem como rotinas responsáveis pela conversão das séries temporais brutas em imagens de gráficos *candlestick*. Em seguida, foi implementada uma arquitetura de rede neural convolucional (*convolutional neural network*, CNN), utilizada como linha de base experimental. Essa arquitetura foi submetida a uma sequência de testes empíricos com o objetivo de avaliar o impacto da variação de hiperparâmetros no processo de treinamento, incluindo resolução das imagens, número de épocas, tamanho da janela temporal, taxa de aprendizado (*learning rate*, LR) e decaimento dinâmico da taxa de aprendizado (*learning rate decay*).

Os resultados preliminares indicam que a principal limitação observada está relacionada à dificuldade de generalização do modelo para dados não vistos. Em vez de aprender padrões do mercado, a CNN demonstrou tendência à memorização dos dados de treinamento, atingindo, em alguns experimentos, acurácia próxima ou igual a 100% nessa etapa, enquanto o desempenho em teste permaneceu na faixa aproximada de 50% a 55%. Esse comportamento caracteriza a ocorrência de *overfitting* e sugere que o volume restrito de amostras, limitado inicialmente aos últimos mil dias de negociação do ativo, pode ser insuficiente para o treinamento da arquitetura convolucional implementada.

As próximas etapas do projeto concentram-se na mitigação desse problema. Pretende-se expandir a base histórica de dados do ativo para além do limite inicial

utilizado, bem como implementar o método de validação cruzada (*k-fold cross-validation*) para aumentar a robustez da avaliação experimental. O estudo também avançará na exploração de outras arquiteturas, como ResNet, além da utilização de técnicas de aprendizado por transferência (*transfer learning*), que consistem na adaptação de modelos previamente treinados ao contexto financeiro deste projeto. Adicionalmente, com o objetivo de viabilizar computacionalmente essas abordagens e obter maior desempenho nos treinamentos, o ambiente de execução, até então local, será migrado para a plataforma Google Colab.

2 Introdução

A predição de movimentos do mercado financeiro constitui um desafio complexo devido à influência simultânea de diversos fatores econômicos, comportamentais e institucionais sobre o preço dos ativos. Tradicionalmente, analistas e investidores utilizam a análise técnica como uma das formas de interpretar o comportamento dos preços, apoiando-se frequentemente em gráficos de *candlestick* para identificar tendências, regiões de suporte e resistência e possíveis padrões de reversão ou continuidade.

Os gráficos de *candlestick* representam visualmente a movimentação de preço de um ativo em determinado intervalo de tempo, geralmente por meio dos valores de abertura, fechamento, máxima e mínima. A combinação sequencial desses elementos permite observar padrões visuais associados ao comportamento do mercado, o que torna esse tipo de representação adequado para investigações envolvendo técnicas de visão computacional.

Com os avanços recentes na área de inteligência artificial, especialmente em *deep learning*, tornou-se possível investigar modelos capazes de reconhecer automaticamente padrões em dados visuais. Nesse contexto, trabalhos como o de Kusuma et al. (2019) exploram o uso de redes neurais profundas aplicadas a gráficos de *candlestick* para a predição de movimentos do mercado financeiro.

Dessa forma, este projeto tem como motivação principal investigar a viabilidade da aplicação de modelos de visão computacional na interpretação automatizada de gráficos financeiros. Para isso, são utilizadas imagens geradas a partir de séries temporais de preços, tendo como estudo inicial o par de moedas USDT/BRL, com dados coletados por meio da API da *exchange* Binance. Nesta etapa preliminar, o foco

concentrou-se na construção do pipeline de coleta e pré-processamento dos dados, bem como na implementação e avaliação inicial de uma rede neural convolucional utilizada como linha de base experimental.

Os resultados obtidos nessa fase inicial permitem identificar limitações importantes do modelo e orientar as próximas etapas do projeto, especialmente no que se refere à ampliação da base de dados, à melhoria dos métodos de validação e à utilização de outras arquiteturas, como modelos baseados em ResNet e aprendizado por transferência.

3 Objetivos

3.1 Objetivo Geral

Investigar, implementar e avaliar o desempenho de diferentes arquiteturas de redes neurais baseadas em visão computacional na predição de tendências de ativos financeiros, utilizando como entrada representações visuais de gráficos de *candlestick*.

Nesta etapa preliminar, o foco concentrou-se na implementação do *pipeline* inicial de coleta e pré-processamento dos dados, bem como na construção e avaliação de uma rede neural convolucional utilizada como linha de base experimental.

3.2 Objetivos Específicos

- Realizar o estudo de fundamentos de análise técnica para compreender a semântica e os padrões visuais presentes nos gráficos de *candlestick*;
- Desenvolver *scripts* para a coleta automatizada de dados históricos de ativos financeiros, com foco inicial no par USDT/BRL por meio da API da Binance;
- Implementar um *pipeline* de pré-processamento para converter séries temporais financeiras em representações visuais de gráficos *candlestick*;
- Implementar e treinar uma arquitetura inicial de rede neural convolucional, utilizando-a como linha de base para os experimentos preliminares;
- Avaliar empiricamente o impacto de diferentes hiperparâmetros no desempenho do modelo, incluindo resolução das imagens, janela temporal, número de épocas, *learning rate* e *learning rate decay*;
- Analisar os resultados obtidos com base em métricas de classificação,

identificando limitações de generalização e ocorrência de *overfitting*;

4 Detalhamento das Atividades Desenvolvidas

Esta seção apresenta as principais atividades desenvolvidas na etapa preliminar do projeto, abrangendo desde a coleta dos dados financeiros até a construção do conjunto de imagens, implementação da arquitetura de rede neural e execução dos experimentos iniciais. O desenvolvimento foi organizado em módulos, de modo a estruturar o fluxo completo do sistema: aquisição dos dados, pré-processamento, geração das imagens, treinamento do modelo e avaliação dos resultados.

4.1 Coleta e Organização dos Dados

A primeira etapa desenvolvida consistiu na coleta automatizada dos dados históricos do ativo financeiro utilizado nos experimentos. Para isso, foram implementados *scripts* em linguagem Python responsáveis por acessar a API da *exchange* Binance e extrair informações referentes ao par de moedas USDT/BRL.

O conjunto inicial de dados foi composto por 1.000 dias de negociação. As informações extraídas contemplaram os principais atributos financeiros presentes em séries temporais de mercado: preço de abertura, preço de fechamento, máxima, mínima e volume negociado. Após a coleta, os dados foram armazenados em um arquivo no formato CSV, utilizado como entrada para os módulos posteriores de pré-processamento e geração das imagens *candlestick*. Essa separação permitiu organizar o fluxo do projeto em etapas independentes, distinguindo o processo de aquisição dos dados da etapa de transformação visual das amostras.

Embora o volume tenha sido extraído e armazenado junto aos demais atributos financeiros, nesta etapa preliminar os experimentos concentraram-se nas representações visuais baseadas nos preços de abertura, fechamento, máxima e mínima. A inclusão do indicador de volume poderá ser avaliada em etapas futuras, considerando que estudos anteriores, como Kusuma et al. (2019), também investigaram essa variação, embora sem ganhos expressivos de desempenho.

4.2 Pré-processamento e Definição dos Rótulos

Para transformar os dados financeiros em um problema de aprendizado supervisionado, foi adotada uma estratégia de criação de amostras por janelas deslizantes (*sliding window*) sobre a série temporal. Essa abordagem consiste em percorrer o histórico de preços com uma janela de tamanho fixo, de modo que cada amostra represente um intervalo contínuo de negociação.

Nesta etapa, foram avaliadas janelas de 20 e 30 dias. Cada janela foi utilizada como base para a geração de uma imagem de gráfico candlestick, fornecendo ao modelo um contexto visual anterior ao movimento que se desejava prever.

O rótulo de cada amostra foi definido com base na direção do preço de fechamento do dia imediatamente posterior à janela analisada. Dessa forma, quando o fechamento posterior apresentava valorização em relação ao fechamento anterior, a amostra era classificada como tendência de alta (*UP*). Caso contrário, era classificada como tendência de baixa (*DOWN*). Assim, o problema foi estruturado como uma tarefa de classificação binária.

4.3 Geração das Imagens Candlestick

Após a organização das janelas temporais, foi desenvolvido um *pipeline* responsável por converter cada intervalo de dados financeiros em uma representação visual no formato de gráfico *candlestick*. Essa etapa permitiu estruturar o problema de predição como uma tarefa de visão computacional, na qual a rede neural recebe imagens como entrada em vez de valores tabulares diretamente.

As imagens foram geradas de forma simplificada, destacando apenas os componentes visuais dos *candles*, isto é, seus corpos e pavios, formados a partir dos preços de abertura, fechamento, máxima e mínima. Nesta etapa preliminar, não foram incluídos elementos adicionais como eixos, legendas, grades, textos ou representação gráfica do volume negociado. Essa escolha teve como objetivo manter a entrada visual mais direta e concentrada na formação dos *candles*.

A resolução das imagens foi tratada como um dos hiperparâmetros avaliados durante os experimentos. Foram geradas imagens nas resoluções de 50x50, 100x100 e 224x224 pixels, com o objetivo de comparar diferentes níveis de detalhamento visual e custo computacional. Em resoluções menores, há menor demanda de processamento, mas também maior risco de perda de detalhes relevantes dos *candles*. Já resoluções maiores preservam melhor a estrutura visual dos gráficos, embora exijam maior capacidade computacional durante o treinamento.

4.4 Normalização das Imagens

Antes de serem utilizadas como entrada da rede neural, as imagens geradas passaram por um processo de normalização estatística. Inicialmente, considerou-se a possibilidade de utilizar parâmetros genéricos de normalização empregados em modelos treinados sobre bases amplas de imagens, como a ImageNet. No entanto, por se tratar de um domínio visual específico, composto por gráficos financeiros e não por imagens naturais, optou-se por calcular a média e o desvio padrão diretamente a partir do próprio conjunto de imagens do projeto.

Essa normalização customizada foi aplicada aos canais de cor RGB das imagens, buscando adequar a escala dos valores de entrada e favorecer a estabilidade do processo de treinamento. Nos experimentos realizados, observou-se que a normalização específica do *dataset* contribuiu para acelerar a convergência do modelo durante o treinamento, embora não tenha sido suficiente para resolver o problema de generalização observado nos dados de teste.

4.5 Implementação da Rede Neural Convolucional

Para a construção do modelo preditivo inicial, foi utilizado o framework PyTorch, com a implementação de uma arquitetura de rede neural convolucional. A arquitetura adotada foi baseada no modelo proposto por Kusuma et al. (2019), utilizado como referência inicial para estabelecer uma linha de base experimental no projeto.

De forma geral, a rede implementada seguiu a estrutura da CNN apresentada no artigo de referência, composta por blocos de camadas convolucionais 2D, camadas de MaxPooling, camadas de regularização por Dropout e, ao final, camadas densas responsáveis pela classificação. No modelo de Kusuma et al. (2019), a arquitetura utiliza quatro camadas convolucionais com função de ativação ReLU, intercaladas com camadas de MaxPooling, seguidas por etapas de Dropout, uma camada densa intermediária e uma camada final com duas saídas, correspondente à classificação binária do movimento do ativo.

As camadas convolucionais têm a função de extrair padrões visuais das imagens de entrada, como bordas, formas e combinações entre corpos e pavios dos *candles*. As camadas de MaxPooling reduzem a dimensionalidade dos mapas de características, preservando as ativações mais relevantes e tornando a representação mais compacta para as etapas seguintes. Já as camadas de Dropout atuam como

mecanismo de regularização, reduzindo a dependência excessiva entre neurônios durante o treinamento e buscando mitigar o *overfitting*.

Após a extração das características visuais, as camadas densas realizam a combinação dessas informações para produzir a classificação final da amostra em uma das duas classes possíveis: tendência de alta ou tendência de baixa. O treinamento foi conduzido utilizando a função de perda Cross-Entropy, adequada para problemas de classificação binária ou multiclasse, em conjunto com o otimizador Adam, responsável por ajustar os pesos da rede ao longo das épocas de treinamento.

5 Resultados Preliminares e Discussão

Com a implementação do *pipeline* de coleta, pré-processamento, geração de imagens e treinamento da rede neural convolucional, foi conduzida uma sequência de experimentos preliminares com o objetivo de avaliar o comportamento da arquitetura diante de diferentes configurações de hiperparâmetros. Os testes buscaram observar principalmente a capacidade de aprendizado do modelo, sua convergência durante o treinamento e seu desempenho em dados não vistos.

Nesta etapa preliminar, foram avaliadas variações no tamanho da janela temporal, na resolução das imagens, no número de épocas, na taxa de aprendizado e na aplicação de decaimento dinâmico da taxa de aprendizado. A Tabela 1 apresenta um resumo dos principais resultados obtidos.

Tabela 1 – Resumo dos experimentos preliminares realizados

Experimento	Janela	Resolução	Épocas	Acurácia Treino	Acurácia Teste	Observação Principal
EXP-01	20 dias	50x50	10	52.87%	45.92%	Modelo não convergiu adequadamente
EXP-02	20 dias	50x50	50	81.48%	55.10%	Melhora no treino, mas com indícios de overfitting
EXP-03	20 dias	50x50	50	58.62%	46.94%	Dcaimento da taxa de aprendizado aplicado de forma prematura
EXP-04	20 dias	50x50	50	88.25%	52.04%	Normalização específica acelerou a convergência, mas não resolveu a

						generalização
EXP-05	20 dias	224x224	50	100.00%	51.53%	Alta acurácia no treino, com baixo desempenho em teste
EXP-06	30 dias	224x224	50	100.00%	55.15%	Melhor resultado de teste, mas ainda com forte overfitting
EXP-07	30 dias	100x100	50	97.42%	50.00%	Resolução intermediária não melhorou a generalização
EXP-08	30 dias	224x224	50	99.61%	48.45%	Taxa de aprendizado maior com decaimento não trouxe ganho em teste

Os resultados indicam que a arquitetura implementada foi capaz de aprender os padrões presentes no conjunto de treinamento, especialmente nos experimentos com maior número de épocas e imagens de maior resolução. No entanto, esse aprendizado não se refletiu de forma consistente no conjunto de teste. Em diferentes configurações, a acurácia de treinamento atingiu valores muito elevados, chegando a 100% em alguns experimentos, enquanto a acurácia de teste permaneceu próxima da faixa de 50% a 55%.

Esse comportamento evidencia a ocorrência de *overfitting*, isto é, uma tendência do modelo a memorizar características específicas do conjunto de treinamento em vez de aprender padrões suficientemente generalizáveis para dados não vistos. O fenômeno tornou-se mais evidente nos experimentos EXP-05 e EXP-06, nos quais a rede atingiu acurácia perfeita no treinamento, mas manteve desempenho limitado no teste.

O EXP-01, utilizado como linha de base inicial, apresentou baixo desempenho tanto no treinamento quanto no teste, indicando dificuldade de convergência com apenas 10 épocas e imagens de 50x50 pixels. Com o aumento para 50 épocas no EXP-02, houve melhora significativa na acurácia de treino, demonstrando que o modelo passou a aprender os dados apresentados. Entretanto, a diferença entre treino e teste já indicava limitação de generalização.

Nos experimentos seguintes, foram avaliadas estratégias como decaimento da taxa de aprendizado, normalização específica do conjunto de imagens, aumento da resolução e ampliação da janela temporal. A normalização customizada contribuiu

para melhorar o processo de convergência, enquanto a janela de 30 dias apresentou o melhor desempenho de teste observado, com acurácia de 55,15% no EXP-06. Ainda assim, a diferença entre a acurácia de treino e teste permaneceu elevada.

A variação da resolução das imagens também apresentou resultados relevantes. Imagens em 50x50 pixels apresentaram menor custo computacional, mas limitaram a representação visual dos candles. A resolução de 224x224 pixels preservou melhor os detalhes gráficos e favoreceu o aprendizado no conjunto de treinamento, porém não foi suficiente para melhorar substancialmente a generalização. Já a resolução intermediária de 100x100 pixels não apresentou ganho relevante, resultando em desempenho de teste equivalente a 50%.

De modo geral, os resultados indicam que o ajuste isolado de hiperparâmetros não foi suficiente para superar a limitação de generalização observada na arquitetura convolucional inicial. As variações testadas contribuíram para compreender o comportamento do modelo, mas a diferença persistente entre treino e teste indica que a continuidade do projeto deve considerar novas estratégias experimentais, como a ampliação da base histórica, o aprimoramento dos métodos de validação e a avaliação de arquiteturas mais robustas.

6 Conclusões Parciais

A etapa preliminar do projeto permitiu consolidar a primeira versão funcional do sistema proposto, contemplando desde a coleta dos dados históricos do par USDT/BRL até a geração das imagens candlestick, implementação da rede neural convolucional e execução dos experimentos iniciais.

Os experimentos realizados demonstraram que a arquitetura convolucional implementada passou a se ajustar progressivamente ao conjunto de treinamento à medida que foram alterados parâmetros como número de épocas, resolução das imagens, normalização dos dados e tamanho da janela temporal. Em algumas configurações, a acurácia de treino atingiu valores muito elevados, estabilizando-se próxima de 100%, acompanhada de baixa perda durante o treinamento. Entretanto, esse comportamento não se refletiu no conjunto de teste, cuja acurácia permaneceu próxima da faixa de 50% a 55%. Essa discrepância evidenciou a ocorrência de *overfitting*, indicando que o modelo apresentou tendência à memorização dos dados de treinamento, sem generalizar adequadamente para dados não vistos.

Apesar dessa limitação, os resultados obtidos são relevantes para o andamento do projeto, pois permitiram estabelecer uma linha de base experimental e identificar os principais desafios da abordagem inicial. A partir dos testes realizados, observou-se que alterações isoladas em hiperparâmetros não foram suficientes para produzir ganhos consistentes de generalização.

Como continuidade, pretende-se investigar estratégias que possam contribuir para uma avaliação mais robusta do modelo, incluindo a ampliação da base histórica de dados, a implementação de validação cruzada (*k-fold cross-validation*) e a migração do ambiente de treinamento para a plataforma Google Colab. Além disso, será priorizada a avaliação de arquiteturas pré-treinadas, especialmente modelos baseados em ResNet, por meio de técnicas de aprendizado por transferência, com o objetivo de comparar seu desempenho com a CNN construída nesta etapa inicial.

7 Bibliografia

KUSUMA, R. M. I. et al. Using Deep Learning Neural Networks and Candlestick Chart Representation to Predict Stock Market. arXiv preprint arXiv:1903.12258, 2019. Disponível em: <https://arxiv.org/abs/1903.12258>. Acesso em: 08 mar. 2026.